

线性分类器

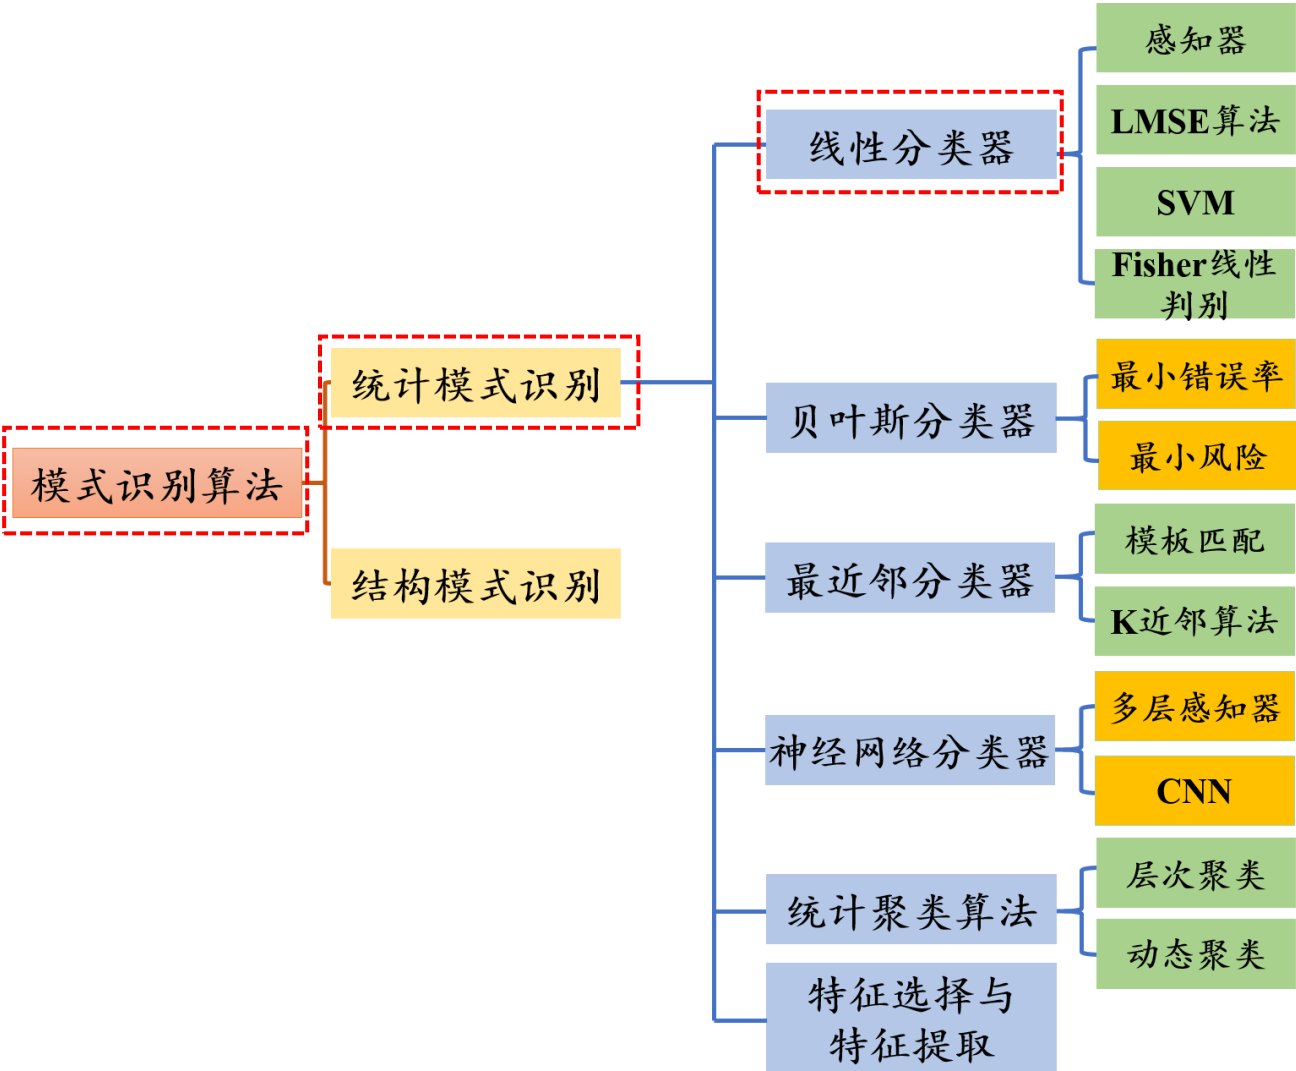
张俊超

中南大学
航空航天学院





模式识别-线性分类器





模式识别-线性分类器

本章主要内容:

主要讨论有监督的分类问题

- ◆ 线性判别
- ◆ 感知器算法
- ◆ LMSE算法(HK算法)
- ◆ Fisher线性判别分析
- ◆ 支持向量机(SVM)
- ◆ 多分类的线性判别



模式识别-线性分类器

学习目标:

- **了解**线性分类器的基本概念
- **理解**感知器算法、LMSE算法、Fisher判别法和SVM
- **应用**线性分类器解决实际分类问题

模式识别-线性分类器


- 根据身高特征，判断待识别个体的高矮程度



● 矮个子的样本


△ 中等个子的样本

■ 高个子的样本



模式识别-线性分类器


- 根据身高和体重特征，判断待识别个体的胖瘦程度



如何找到一个有效的分类决策规则，能够对新的样本正确地分类？

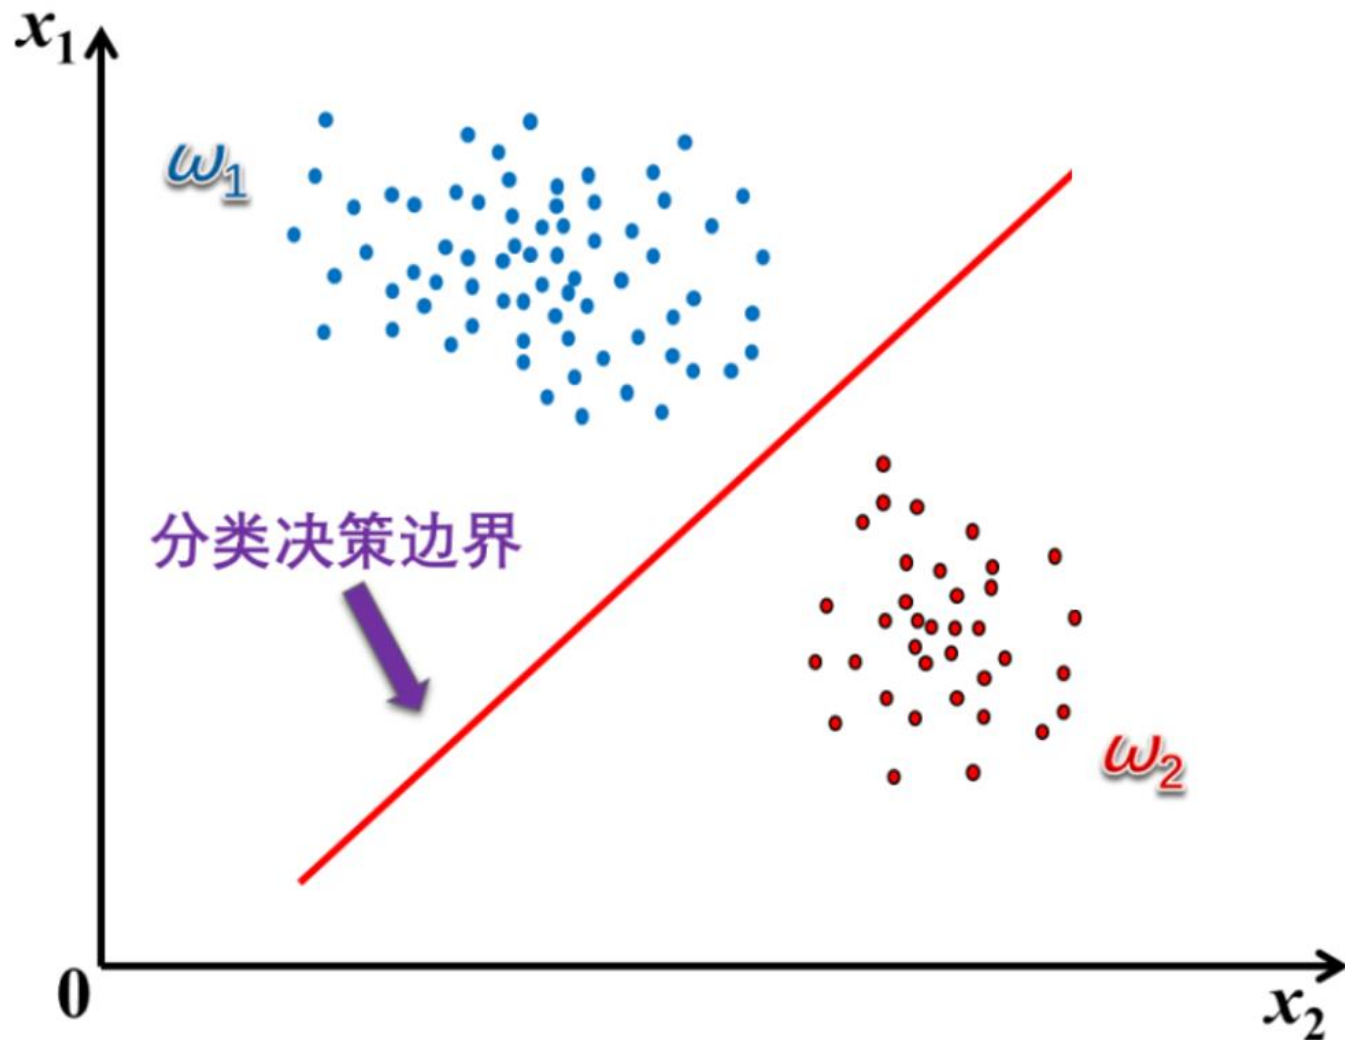


线性分类器 - 线性判别






线性分类器 - 线性判别





线性分类器 - 线性判别





线性分类器 - 线性判别

线性判别函数：判别函数是线性的，可以表示为：

$$G(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + w_0$$

其中：特征向量 $\mathbf{x} = [x_1, x_2, \dots, x_n]^T$

权重 $\mathbf{w} = [w_1, w_2, \dots, w_n]^T$

偏差 w_0



齐次表示为：

$$G(\mathbf{y}) = \boldsymbol{\alpha}^T \mathbf{y}$$

$$\boldsymbol{\alpha} = [w_1, w_2, \dots, w_n, w_0]^T$$

$$\mathbf{y} = [x_1, x_2, \dots, x_n, 1]^T$$

线性分类器 - 线性判别




- 如果特征空间是1维的，线性分类器的分类决策边界就是一个点；
- 如果特征空间是2维的，分类决策边界就是一条直线；
- 如果特征空间是3维的，分类决策边界就是一个平面；
- 如果特征空间是更高维的，分类决策边界就是一个超平面。



线性分类器 - 线性判别

➤Q1:是不是任何一个模式识别问题，都可以找到线性分类决策边界呢？





➤Q2:给定一个样本集，它是线性可分的吗？

线性分类器 - 线性判别



- 样本集的线性可分性:

如果各个类别样本的分布区域互不相交，并且都是凸集，那么它一定是线性可分的。



线性分类器 - 线性判别


除了凸包相交的情形，如果同一类别样本的分布区域是由不连通的子区域组成的，也会带来线性不可分的问题，这种情形的典型案例就是异或问题。





线性分类器 - 线性判别

➤Q1:有没有什么方法很快就能知道样本集是不是线性可分的呢?




➤Q2:有没有什么方法可以将非线性判别问题转化成线性判别问题呢?



线性分类器 - 线性判别

样本距离决策边界的距离 VS 判别函数的绝对值



$$G(1, 2) = 2 - 1 = 1$$

$$G(1, 3) = 3 - 1 = 2$$

$$G(2, 1) = 1 - 2 = -1$$

$$G(3, 1) = 1 - 3 = -2$$

- 直观地发现，当一个样本距离分类边界越远，判别函数的绝对值也越大。
- 判别函数是样本到决策面距离远近的一种度量。

判别函数的几何意义究竟如何呢？

线性分类器 - 线性判别


线性判别函数的几何意义

➤ 决策边界方程为：


$$G(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + w_0 = 0$$

➤ 设样本 $\mathbf{x}_1, \mathbf{x}_2$ 在决策边界上，则有：

$$\mathbf{w}^T \mathbf{x}_1 + w_0 = \mathbf{w}^T \mathbf{x}_2 + w_0 = 0$$



$$\mathbf{w}^T (\mathbf{x}_1 - \mathbf{x}_2) = 0$$



权向量 \mathbf{w} 和决策边界上任一向量正交，即其与决策面法向量方向一致，**方向指向正样本**。



线性分类器 - 线性判别

线性判别函数的几何意义

➤ 设样本 \mathbf{x} 距离决策边界的距离为 r ，其在决策边界上的投影点为 \mathbf{x}_p ，则：


$$\mathbf{x} = \mathbf{x}_p + r \frac{\mathbf{w}}{\|\mathbf{w}\|}$$

➤ 代入判别函数中，可得：

$$G(\mathbf{x}) = \boxed{\mathbf{w}^T \mathbf{x}_p + w_0} + r \frac{\mathbf{w}^T \mathbf{w}}{\|\mathbf{w}\|}$$

$$\downarrow$$
$$G(\mathbf{x}) = r \|\mathbf{w}\|$$

$$\downarrow$$
$$r = \frac{G(\mathbf{x})}{\|\mathbf{w}\|}$$





线性分类器 - 线性判别

◆ 线性判别小结:

- 决策边界在特征空间可以是点、线、面和超平面
- 样本集的线性可分性，仍需深入研究
- 非线性问题可以进一步转化为线性问题(后面章节会学到)

◆ 线性判别函数的几何意义小结:


- 样本到决策边界的距离正比于判别函数的绝对值
- 判别函数大于(或小于)0，表示该样本位于决策边界的正侧(或负侧)
- 权向量与决策边界的法线方向一致，其长度不会影响决策边界在特征空间中的方向，完全可以取 $\|\mathbf{w}\|=1$



线性分类器 - 算法前言

回顾：线性分类器由线性判别函数和相应的分类决策规则构成。

Q1: 线性判别函数是如何得到的呢?

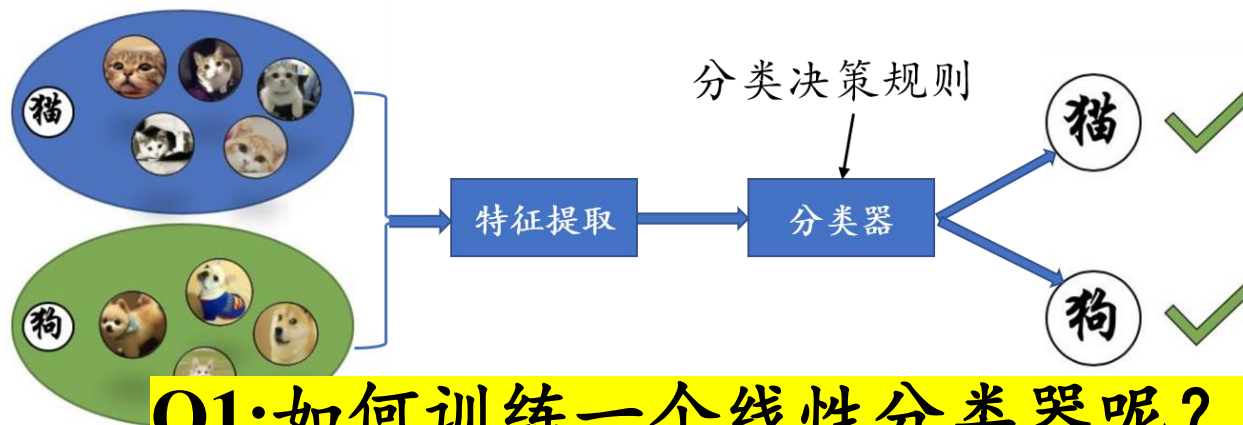


Q2: 一个模式识别问题，我们怎么设计出一个合适的线性分类器，使它能对未知样本进行正确分类呢?

线性分类器 - 算法前言


有监督的分类问题一般流程如下：

➤ 训练(学习)



Q1: 如何训练一个线性分类器呢?


➤ 测试






线性分类器 - 算法前言

给定有标签的样本，训练获得 \mathbf{w}, w_0






线性分类器 - 算法前言





线性分类器 - 算法前言





线性分类器 - 算法前言

解区域的确定:

$$G(\mathbf{y}) = \boldsymbol{\alpha}^T \mathbf{y}$$

$$\boldsymbol{\alpha} = [w_1, w_2, \dots, w_n, w_0]^T$$

$$\mathbf{y} = [x_1, x_2, \dots, x_n, 1]^T$$

对于一组线性可分的样本 $\{\mathbf{y}_1, \mathbf{y}_2, \mathbf{y}_3, \dots, \mathbf{y}_N\}$, 有:

$$G(\mathbf{y}_i) = \begin{cases} \boldsymbol{\alpha}^T \mathbf{y}_i > 0 & \mathbf{y}_i \in \omega_1 \\ \boldsymbol{\alpha}^T \mathbf{y}_i < 0 & \mathbf{y}_i \in \omega_2 \end{cases}$$

令

$$\mathbf{y}_i' = \begin{cases} \mathbf{y}_i & \mathbf{y}_i \in \omega_1 \\ -\mathbf{y}_i & \mathbf{y}_i \in \omega_2 \end{cases}$$

书中为了方便,
把 \mathbf{y}' 仍然记作 \mathbf{y}

$$\boldsymbol{\alpha}^T \mathbf{y}_i > 0, (i = 1, 2, \dots, N)$$

规范化增广样本向量



线性分类器 - 算法前言

对于一组线性可分的样本 $\{\mathbf{y}_1, \mathbf{y}_2, \mathbf{y}_3, \dots, \mathbf{y}_N\}$, 如果一个权向量 $\boldsymbol{\alpha}^*$ 满足:

$$(\boldsymbol{\alpha}^*)^T \mathbf{y}_i > 0, (i = 1, 2, \dots, N)$$


则称 $\boldsymbol{\alpha}^*$ 为一个解向量。

- 对于一个样本 \mathbf{y}_i , $\boldsymbol{\alpha}^T \mathbf{y}_i = 0$ 定义了权空间(见补充材料)中一个过原点的超平面。
- 处于超平面正侧的任何一个向量都能使 $\boldsymbol{\alpha}^T \mathbf{y}_i > 0$ 。
- 所有样本对应超平面的正侧的交集就是解区域。



线性分类器 - 算法前言

$$\begin{cases} \mathbf{y}_1, \mathbf{y}_2 \in \omega_1 \\ \mathbf{y}_3, \mathbf{y}_4 \in \omega_2 \end{cases}$$





线性分类器 - 算法前言

线性分类器训练一般思路如下：

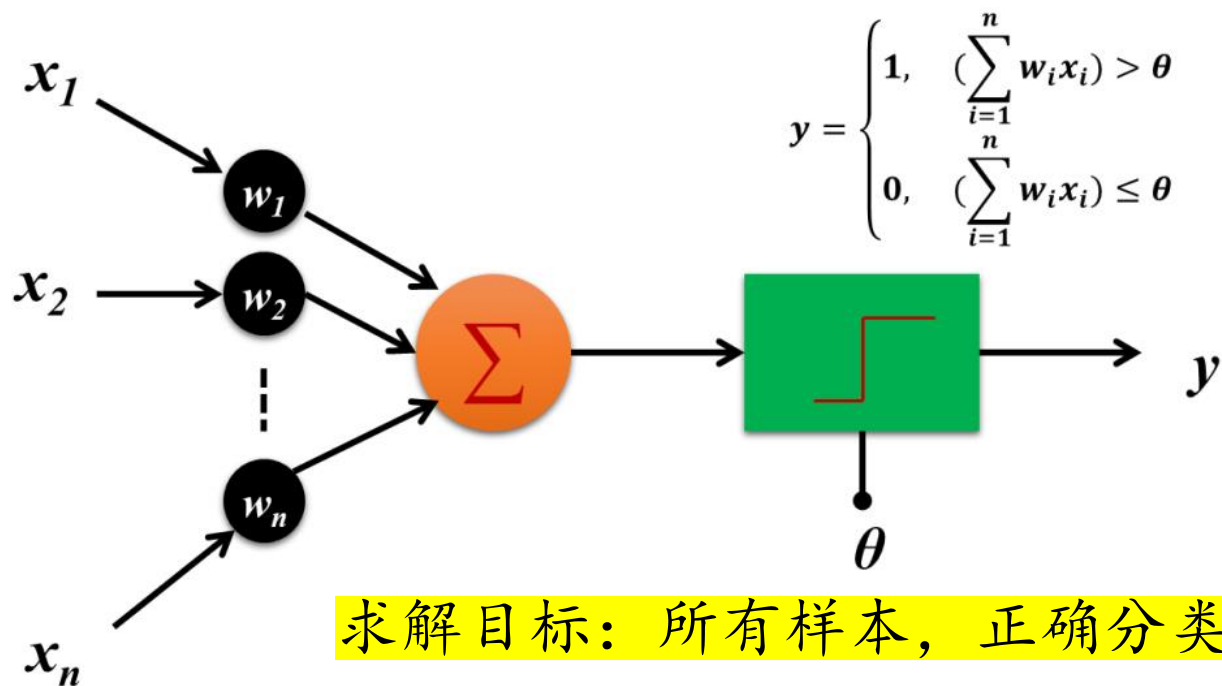
- 首先设定一个标量的**准则函数**，使其值能够代表解的优劣程度，准则函数值越小，说明越符合要求，越好；
- 通过寻找准则函数的极小值，就能找到最优的一个解。

注意：准则函数和判别函数的区别

线性分类器 - 感知器算法

感知器：

1957年，美国计算机科学家罗森布拉特(F. Rosenblatt)提出的。是一种神经元模型，一个神经元的“**树突**”搜集的信号，达到一定的激发阈值，就会激活“**轴突**”的输出。



求解目标：所有样本，正确分类



线性分类器 - 感知器算法

准则函数：所有错分样本的判别函数值之和，再乘以(-1)，

【自学】：

1. 什么是梯度下降算法？

2. 为什么梯度下降要选负梯度的方向？

3. 每次移动的步长(学习率)能不能选太大？

学习网址：

<https://blog.csdn.net/pengchengliu/article/details/80932232>

$$J_p(\alpha) = \sum_{\alpha^T y_i \leq 0} (-\alpha^T y_i)$$



$$\alpha^* = \arg \min_{\alpha} J_p(\alpha)$$



梯度下降算法

$$\alpha(t+1) = \alpha(t) - \rho_t \nabla J_p(\alpha)$$



$$\nabla J_p(\alpha) = - \sum_{\alpha^T y_i \leq 0} y_i$$

$$\alpha(t+1) = \alpha(t) + \rho_t \sum_{\alpha^T y_i \leq 0} y_i$$



线性分类器 - 感知器算法

所有样本

感知器算法具体步骤:


- (1) 任意选择初始的权向量 $\alpha(0)$, 置 $t = 0$
- (2) 修正权向量: $\alpha(t+1) = \alpha(t) + \rho_t \sum_{\alpha^T y_i \leq 0} y_i$
- (3) $t = t + 1$, 重复(2), 直至对所有样本都有 $\alpha(t)^T y > 0$

单样本

感知器算法具体步骤:


- (1) 任意选择初始的权向量 $\alpha(0)$, 置 $t = 0$
- (2) 考查样本 y_i , 若 $\alpha(t)^T y_i \leq 0$, 则 $\alpha(t+1) = \alpha(t) + \rho_t y_i$
- (3) 考察另一个样本, 重复(2), 直至所有样本都正确分类

线性分类器 - 感知器算法



$$\alpha(0) = (0, 0), \rho = 1$$

$$\alpha(1) = \mathbf{a} + \mathbf{b} - \mathbf{c}$$



$$\alpha(0) = (0, 0), \rho = 1$$

$$\alpha(1) = \mathbf{a}$$

$$\alpha(2) = \mathbf{a} - \mathbf{c}$$

Q1: 如何评判哪一个解更优呢?



线性分类器 - 感知器算法

Q: 对于线性可分的样本集，感知器算法一定能找到最优解吗？

可以证明，对于线性可分的样本集，采用梯度下降的迭代算法，经过有限次修正后一定会收敛到一个解向量。

$$\alpha(0) = \mathbf{0}$$


$$\alpha(1) = \mathbf{0} + \mathbf{y}_1$$

$$\alpha(2) = \alpha(1) + \mathbf{y}_3$$

$$\alpha(3) = \alpha(2) + \mathbf{y}_1$$

$$\alpha(4) = \alpha(3) + \mathbf{y}_3$$

$$\alpha(5) = \alpha(4) + \mathbf{y}_1$$





线性分类器 - 感知器算法

例题：已知两类训练样本， $(0,0), (0,1)$ 属于 w_1 ,
 $(1,0), (1,1)$ 属于 w_2 , 试用感知器算法求 α^*

解：

1. 样本增广化和规范化： $y_1=(0,0,1)'$, $y_2=(0,1,1)'$, $y_3=(-1,0,-1)'$,
 $y_4=(-1,-1,-1)'$

2. 权向量初始化 $\alpha(0)=\mathbf{0}$, 学习速率 $\rho=1$

$$t=1, \alpha(0)^T y_1 = 0, \alpha(1) = \mathbf{0} + y_1 = (0,0,1)^T$$

$$t=2, \alpha(1)^T y_2 = 1 > 0, \alpha(2) = \alpha(1) = (0,0,1)^T$$

$$t=3, \alpha(2)^T y_3 = -1 < 0, \alpha(3) = \alpha(2) + y_3 = (-1,0,0)^T$$

$$t=4, \alpha(3)^T y_4 = 1 > 0, \alpha(4) = \alpha(3) = (-1,0,0)^T$$

⋮



线性分类器 - 感知器算法


权向量: $\alpha^* = (-2, 0, 1)$

决策边界方程为: $-2x_1 + 0 \cdot x_2 + 1 = 0$

【作业】

$\alpha(0) = (1, 1, 1)$, $\rho = 2$

给出最优权向量和
决策边界的方程,
并给出图形表示。





线性分类器 -

```
%%  
Y = [0 0 1;  
      0 1 1;  
      -1 0 -1;  
      -1 -1 -1];  
p = 1;% learning rate  
a_cur = [0 0 0];  
while(1)  
    c = 0;  
    for i = 1:size(Y,1)  
        tmp = a_cur(end,:)*Y(i,:);  
        if tmp>0  
            c = c + 1;  
        else  
            a_t = a_cur(end,:) + p*Y(i,:);  
            a_cur = [a_cur;a_t];  
        end  
    end  
    if c == size(Y,1)  
        break;  
    end  
end
```



线性分类器 - 感知器算法

案例：手写数字的识别

基于Mnist数据集，请用感知器算法对手写数字“8”和“6”进行识别。









线性分类器 - 感知器算法

【说明】

1. 数据集(提供, 去学习委员那里copy)
2. 数据集结构:

名称 ▲	值
 test_images	28x28x10000 double
 test_labels1	1x10000 double
 train_images	28x28x60000 double
 train_labels1	1x60000 double

3. Label: 范围[0,9], 分别对应数字0-9
4. 图像大小是28*28, 需要转成向量(提取特征或直接拉成784维的向量)
5. 训练感知器是基于train_images和train_labels1, 测试时用测试图像



线性分类器 - 感知器算法

【要求】

1. 编程语言：Matlab (或Python)
2. 不能使用额外的库函数，自己编写实现感知器算法。
3. 采用基于单样本(或集体样本)的梯度下降算法。
4. 调整学习率，总结算法的求解精度和速度，与学习率之间的关系。
5. 采用不同数量的训练样本(比如5000，3000，1000，500)训练感知器，对比测试结果。
6. 提交实验报告和源代码(命名规则：感知器_学号_姓名，
先发给助教，助教再发到邮箱：
zhangjunchao_work@163.com)
7. 作业迟交 n 天，本次作业分数乘以 0.98^n 。



线性分类器 - 感知器算法

小结:

1. 权向量的解区域:

- 对于一个样本 \mathbf{y}_i , $\mathbf{a}^T \mathbf{y}_i = 0$ 定义了权空间中一个过原点的超平面。
- 处于超平面正侧的任何一个向量都能使 $\mathbf{a}^T \mathbf{y}_i > 0$ 。
- 所有样本对应超平面的正侧的交集就是解区域。

2. 感知器算法:

- 只对线性可分的问题有效。
- 不能在解区域中选出最优解。
- 不能对训练样本集是否线性可分作出判断。



线性分类器 - 感知器算法

谢谢聆听！





线性分类器 - 感知器算法

若干素材取自网络，特此致谢！





线性分类器 - 补充材料

权空间：

$$\text{决策面方程: } \boldsymbol{\alpha}^T \mathbf{y} = 0 \quad \mathbf{y} \in \mathbb{R}^n$$



$$\mathbf{y}^T \boldsymbol{\alpha} = 0$$

权向量全体构成一个 n 维的权向量空间， $\boldsymbol{\alpha}^T \mathbf{y} = 0$ 确定了通过权空间原点的超平面，法向量与 \mathbf{y} 一致。