

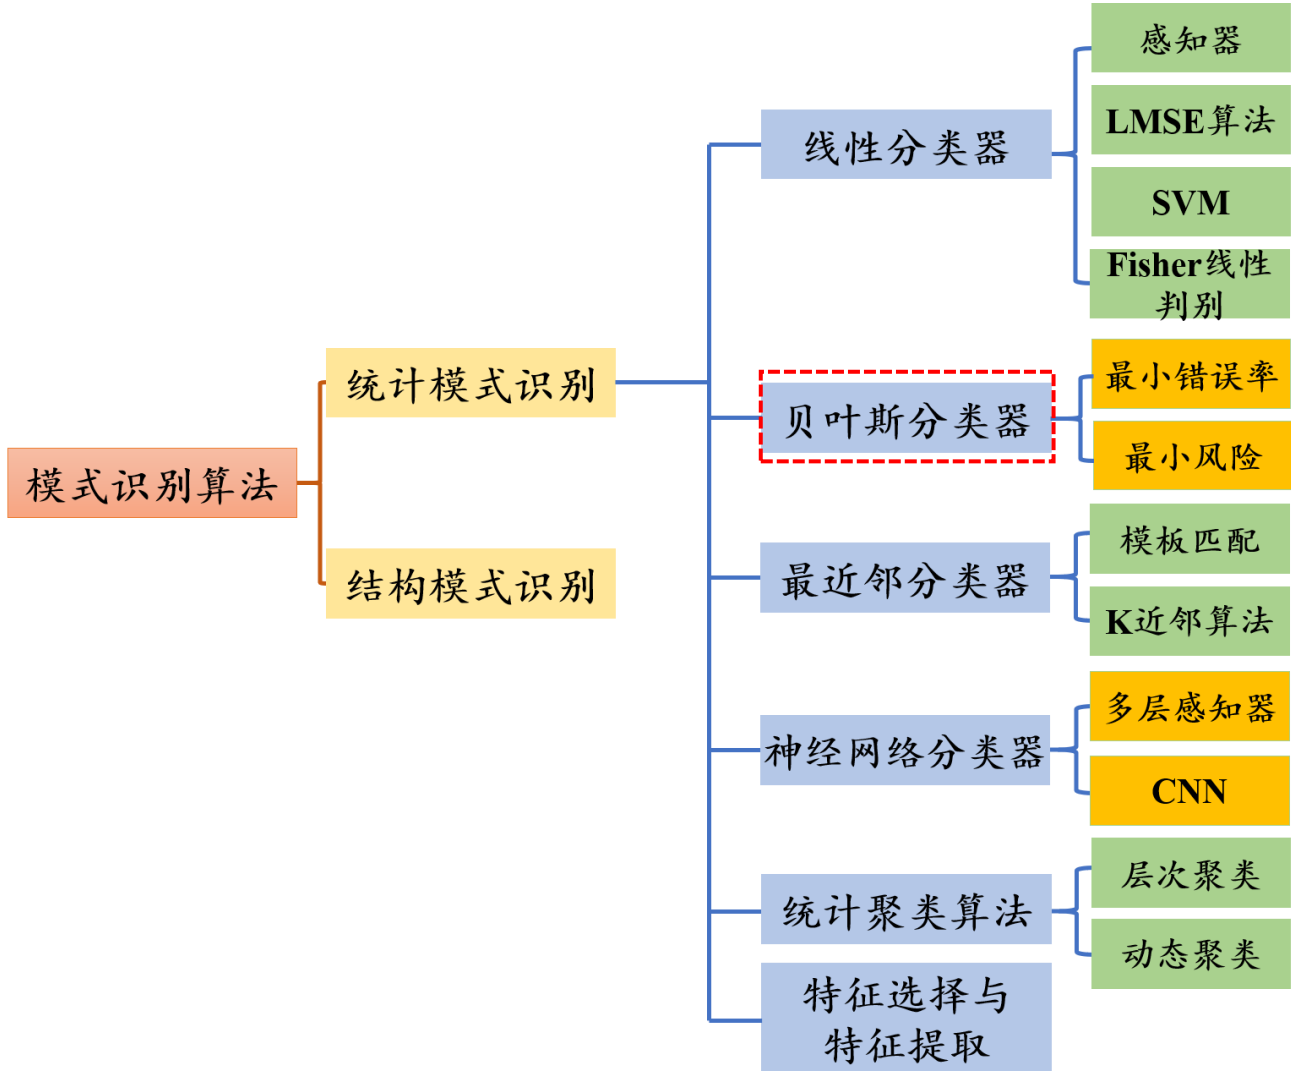
贝叶斯分类器
张俊超

中南大学
航空航天学院





模式识别-贝叶斯分类器





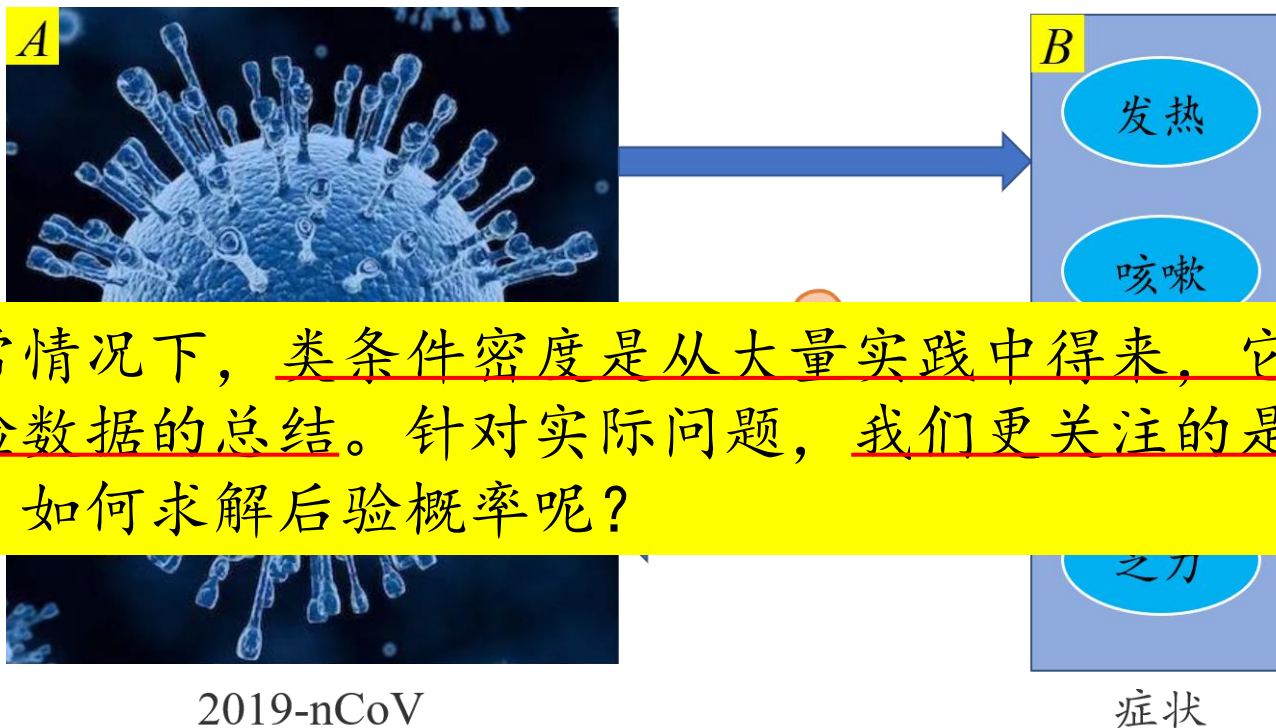
模式识别-贝叶斯分类器

本章主要内容:

主要讨论有监督的分类问题

- ◆ 最小错误率贝叶斯决策
- ◆ 最小风险贝叶斯决策
- ◆ 正态分布概率模型下的最小错误贝叶斯决策
- ◆ 概率密度函数的估计

模式识别-贝叶斯分类器



通常情况下，类条件密度是从大量实践中得来，它是一种经验数据的总结。针对实际问题，我们更关注的是后验概率。如何求解后验概率呢？

➤ 患病(结果)→症状(条件)的概率： $P(B|A)$

类条件密度

➤ 症状(条件)→患病(结果)的概率： $P(A|B)$

后验概率



模式识别-贝叶斯分类器


贝叶斯公式:

后验概率

类条件密度

先验概率

$$P(A|B) = \frac{P(A,B)}{P(B)} = \frac{P(B|A)P(A)}{P(B)}$$



$P(\omega_1 | \mathbf{x})$ vs $P(\omega_2 | \mathbf{x})$

模式识别-贝叶斯分类器

如果在路上我们看到一个人的背影，发现ta有长头发，那么ta是男士还是女士呢？



Who?



$P(\text{男士}|\text{长发})$ 和 $P(\text{女士}|\text{长发})$



模式识别-贝叶斯分类器

求 $P(\text{男士}|\text{长发})$ 和 $P(\text{女士}|\text{长发})$:

假设:

➤ $P(\text{长发}|\text{男士})=0.05$, $P(\text{长发}|\text{女士})=0.7$

➤ $P(\text{男士})=P(\text{女士})=0.5$

则:

$$P(\text{女士}|\text{长发}) > P(\text{男士}|\text{长发}), \text{ta是女士}$$

$$P(\text{男士}|\text{长发}) = \frac{P(\text{长发}|\text{男士}) * P(\text{男士})}{P(\text{长发}|\text{男士}) * P(\text{男士}) + P(\text{长发}|\text{女士}) * P(\text{女士})} = 0.067$$

$$P(\text{女士}|\text{长发}) = \frac{P(\text{长发}|\text{女士}) * P(\text{女士})}{P(\text{长发}|\text{男士}) * P(\text{男士}) + P(\text{长发}|\text{女士}) * P(\text{女士})} = 0.933$$



模式识别-贝叶斯分类器

先验概率变化了

假设：

$$\triangleright P(\text{长发}|\text{男士})=0.05, \quad P(\text{长发}|\text{女士})=0.7$$

$$\triangleright P(\text{男士})=0.8, \quad P(\text{女士})=0.2$$

则：

$$P(\text{男士}|\text{长发}) = \frac{P(\text{长发}|\text{男士}) * P(\text{男士})}{P(\text{长发}|\text{男士}) * P(\text{男士}) + P(\text{长发}|\text{女士}) * P(\text{女士})} = 0.22$$

$$P(\text{女士}|\text{长发}) = \frac{P(\text{长发}|\text{女士}) * P(\text{女士})}{P(\text{长发}|\text{男士}) * P(\text{男士}) + P(\text{长发}|\text{女士}) * P(\text{女士})} = 0.78$$



贝叶斯分类器-最小错误率决策

- 最大后验概率(最小错误率)的贝叶斯分类器

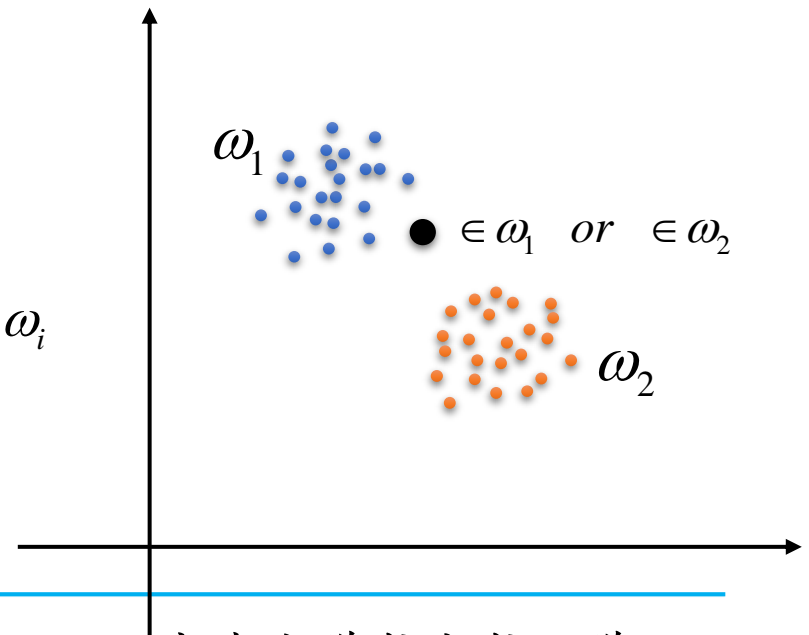
决策规则： 若 $P(\omega_i | \mathbf{x}) = \max_{j=1,2,\dots,c} P(\omega_j | \mathbf{x})$, 则 $\mathbf{x} \in \omega_i$

最大后验概率决策会存在误分类吗？

$$P(\omega_i | \mathbf{x}) = \frac{P(\mathbf{x} | \omega_i) P(\omega_i)}{P(\mathbf{x})}$$




若 $P(\omega_i | \mathbf{x}) = \max_{j=1,2,\dots,c} P(\mathbf{x} | \omega_j) P(\omega_j)$, 则 $\mathbf{x} \in \omega_i$



贝叶斯分类器-最小错误率决策

- 误分类
- 错误率:
- 正确率:

$$P(c) = 1 - P(e)$$



$$\begin{aligned}
 P(e) &= P(x \text{ 在 } \Omega_2 \text{ 中} | \omega_1) + P(x \text{ 在 } \Omega_1 \text{ 中} | \omega_2) \\
 &= \int_{\Omega_2} P(\omega_1) p(x | \omega_1) dx + \int_{\Omega_1} P(\omega_2) p(x | \omega_2) dx \\
 &= P(\omega_1) \int_{\Omega_2} p(x | \omega_1) dx + P(\omega_2) \int_{\Omega_1} p(x | \omega_2) dx \\
 &= P(\omega_1) P_1(e) + P(\omega_2) P_2(e)
 \end{aligned}$$


ω_1 类样本决策为 ω_2 类的错误率



贝叶斯分类器-最小错误率决策

为什么最大后验概率决策就是最小错误率决策呢？

$$P(e) = \int_{\Omega_2} P(\omega_1)p(x | \omega_1)dx + \int_{\Omega_1} P(\omega_2)p(x | \omega_2)dx$$






贝叶斯分类器-最小错误率决策

最小错误率贝叶斯分类器的分类边界是什么样的呢？

决策边界为： $P(\omega_i | \mathbf{x}) = P(\omega_j | \mathbf{x})$






贝叶斯分类器-最小错误率决策

最小错误率贝叶斯分类器的分类边界一定是线性的吗？

分类决策边界不一定是线性的，也不一定是连续的。





贝叶斯分类器-最小错误率决策

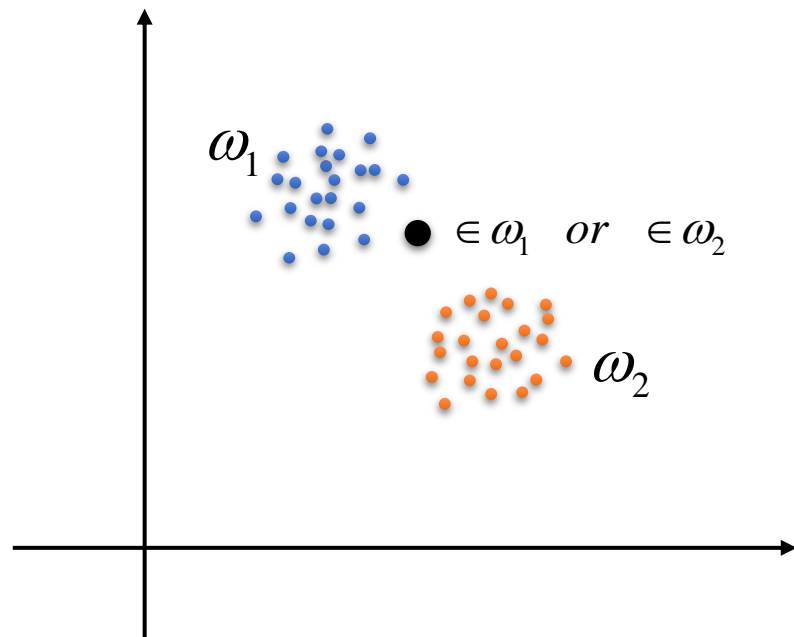
如何训练最小错误率贝叶斯分类器，使其实现分类呢？

若 $P(\omega_i | \mathbf{x}) = \max_{j=1,2,\dots,c} P(\mathbf{x} | \omega_j) P(\omega_j)$, 则 $\mathbf{x} \in \omega_i$

➤ 根据已知样本估计类条件密度和先验概率(书中第3章的内容)

➤ 计算待测样本的后验概率

➤ 根据最大后验概率决策，进行分类





贝叶斯分类器-最小错误率决策

举例：[数据真实性不具参考意义，纯为说明问题]

2019年底，新型冠状病毒(2019-nCoV)的发病率为两万分之一，普通流感的发病率可高达30%。易感人群中99%的人感染2019-nCoV病例曾出现过发热、咳嗽等急性呼吸道感染症状，而同样的易感人群中80%的普通流感患者也出现过同样症状。

Q: 现有一位患者属于易感人群，并出现了发热、咳嗽等急性呼吸道感染症状，请问是否应当按照人2019-nCoV疑似病例对待？



贝叶斯分类器-最小错误率决策

$$P(2019-nCoV) = \frac{0.00005}{0.00005 + 0.3} = 0.00017$$

$$P(\text{普通流感}) = 0.99983$$

$$P(\text{症状}|2019-nCoV) = 0.99$$

$$P(\text{症状}|\text{普通流感}) = 0.8$$

这样做，合理吗？如果把2019-nCoV误诊为普通流感，后果会怎样？

$$P(2019-nCoV|\text{症状}) = \frac{0.99 * 0.00017}{0.99 * 0.00017 + 0.8 * 0.99983} = 0.0002$$

$$P(\text{普通流感}|\text{症状}) = 0.9998$$

按照最大后验概率决策的话，该患者**不应当**按照2019-nCoV疑似病例对待。



贝叶斯分类器-最小风险贝叶斯决策

- 如果把普通流感误诊为2019-nCoV，后果会怎样？
- 如果把2019-nCoV误诊为普通流感，后果会怎样？

社会风险哪个更大？

- 仅仅考虑最小错误率是不够的
- 还应当把所采取的分类决策所带来的后果考虑进去



最小风险贝叶斯分类器



贝叶斯分类器-最小风险贝叶斯决策

概念:


- 决策: $\alpha_1, \alpha_2, \dots, \alpha_k$
 α_i : 把待识别样本归到 ω_i
- 损失函数: 实际状态为 ω_j , 采取 α_i 决策

$$\lambda(\alpha_i, \omega_j), i = 1, 2, \dots, k, \quad j = 1, 2, \dots, c$$

贝叶斯分类器-最小风险贝叶斯决策

损失函数通常以表格的形式给出(决策表)

表 2-2-1

损 失 决 策	状 态	ω_1	ω_2	...	ω_j	...	ω_m
a_1		$\lambda(a_1, \omega_1)$	$\lambda(a_1, \omega_2)$...	$\lambda(a_1, \omega_j)$...	$\lambda(a_1, \omega_m)$
a_2		$\lambda(a_2, \omega_1)$	$\lambda(a_2, \omega_2)$...	$\lambda(a_2, \omega_j)$...	$\lambda(a_2, \omega_m)$
\vdots			\vdots	...	\vdots	...	\vdots
a_i		$\lambda(a_i, \omega_1)$	$\lambda(a_i, \omega_2)$...	$\lambda(a_i, \omega_j)$...	$\lambda(a_i, \omega_m)$
\vdots		\vdots	\vdots	...	\vdots	...	\vdots
a_u		$\lambda(a_u, \omega_1)$	$\lambda(a_u, \omega_2)$...	$\lambda(a_u, \omega_j)$...	$\lambda(a_u, \omega_m)$



贝叶斯分类器-最小风险贝叶斯决策

➤采取决策 α_i 的期望损失为：

$$R(\alpha_i | \mathbf{x}) = \sum_{j=1}^c \lambda(\alpha_i, \omega_j) P(\omega_j | \mathbf{x}), i = 1, 2, \dots, k$$

➤最小风险贝叶斯决策：

$$\text{若 } R(\alpha_i | \mathbf{x}) = \min_{j=1,2,\dots,k} R(\alpha_j | \mathbf{x}), \text{ 则 } \alpha = \alpha_i$$

➤针对二分类的情况：

$$\begin{cases} \lambda_{11}P(\omega_1 | \mathbf{x}) + \lambda_{12}P(\omega_2 | \mathbf{x}) < \lambda_{21}P(\omega_1 | \mathbf{x}) + \lambda_{22}P(\omega_2 | \mathbf{x}), \mathbf{x} \in \omega_1 \\ \lambda_{11}P(\omega_1 | \mathbf{x}) + \lambda_{12}P(\omega_2 | \mathbf{x}) > \lambda_{21}P(\omega_1 | \mathbf{x}) + \lambda_{22}P(\omega_2 | \mathbf{x}), \mathbf{x} \in \omega_2 \end{cases}$$

$$\text{其中, } \lambda_{ij} = \lambda(\alpha_i, \omega_j)$$



贝叶斯分类器-最小风险贝叶斯决策

二分类问题：当 $\lambda_{11} = \lambda_{22} = 0, \lambda_{12} = \lambda_{21} = 1$ 时

$$\begin{cases} \lambda_{11}P(\omega_1 | \mathbf{x}) + \lambda_{12}P(\omega_2 | \mathbf{x}) < \lambda_{21}P(\omega_1 | \mathbf{x}) + \lambda_{22}P(\omega_2 | \mathbf{x}), \mathbf{x} \in \omega_1 \\ \lambda_{11}P(\omega_1 | \mathbf{x}) + \lambda_{12}P(\omega_2 | \mathbf{x}) > \lambda_{21}P(\omega_1 | \mathbf{x}) + \lambda_{22}P(\omega_2 | \mathbf{x}), \mathbf{x} \in \omega_2 \end{cases}$$

其中, $\lambda_{ij} = \lambda(\alpha_i, \omega_j)$



0-1决策表

$$\begin{cases} P(\omega_2 | \mathbf{x}) < P(\omega_1 | \mathbf{x}), \mathbf{x} \in \omega_1 \\ P(\omega_2 | \mathbf{x}) > P(\omega_1 | \mathbf{x}), \mathbf{x} \in \omega_2 \end{cases}$$

最小风险贝叶斯决策 → 最大后验概率决策



贝叶斯分类器-最小风险贝叶斯决策

决策	状态	
	2019-nCoV	普通流感
2019-nCoV	0	1
普通流感	10000	0

$$P(2019-nCoV|症状)=0.0002$$

$$P(普通流感|症状)=0.9998$$

$$\begin{aligned} R(2019-nCoV|症状) &= 0 * P(2019-nCoV|症状) + 1 * P(普通流感|症状) \\ &= 0.9998 \end{aligned}$$

$$\begin{aligned} R(普通流感|症状) &= 10000 * P(2019-nCoV|症状) + 0 * P(普通流感|症状) \\ &= 2 \end{aligned}$$

按照最小风险贝叶斯决策的话，该患者应当按照2019-nCoV疑似病例对待。



模式识别-贝叶斯分类器

- 小结

- 贝叶斯分类器

1. 最小错误率决策(错误率最小化)
2. 最小风险决策(风险最小化)

- 最小风险决策需要事先指定决策表，决策表不同分类结果也不同。
 - 需要事先知道(估计)类条件密度和先验概率。

先验概率：可以从大量重复实验或数据统计中得到

类条件密度估计：估计各个特征维度的联合概率分布。若不独立，很难估计。一般假设各个特征维度相互独立，进而估计联合概率分布，这就是“**朴素贝叶斯分类器**”。



统计决策方法-ROC曲线


- 真阳性(True Positive Rate): 阳性样本被预测正确的比例
- 假阳性(False Positive Rate): 阴性样本被预测错误的比例

真实值	预测值	
	阳性	阴性
阳性	TP	FN
阴性	FP	TN


$$TPR = \frac{TP}{TP + FN} \quad FPR = \frac{FP}{FP + TN}$$

统计决策方法-ROC曲线

AUC(area under ROC curves): 越接近1, 性能越好



(a) ROC 曲线与 AUC



(b) 基于有限样例绘制的 ROC 曲线
与 AUC



统计决策方法-ROC曲线

举例：

样本类别：P(positive)和N(Negative)

样本	预测属于P的概率	真实类别
1	0.1	N
2	0.35	P
3	0.4	N
4	0.8	P



统计决策方法-Roc曲线

- 截断点为0.1(概率 ≥ 0.1 , 就判别为P类)

样本	预测属于P的概率	真实类别
1	0.1	N
2	0.35	P
3	0.4	N
4	0.8	P



真实值	预测值	
	阳性	阴性
阳性	TP=2	FN=0
阴性	FP=2	TN=0

$$TPR = \frac{TP}{TP + FN} = 1$$
$$FPR = \frac{FP}{FP + TN} = 1$$



统计决策方法-Roc曲线

- 截断点为0.35(概率 ≥ 0.35 , 就判别为P类)

样本	预测属于P的概率	真实类别
1	0.1	N
2	0.35	P
3	0.4	N
4	0.8	P



真实值	预测值	
	阳性	阴性
阳性	TP=2	FN=0
阴性	FP=1	TN=1

$$TPR = \frac{TP}{TP + FN} = 1$$
$$FPR = \frac{FP}{FP + TN} = 0.5$$



统计决策方法-ROC曲线

- 截断点为0.4(概率 ≥ 0.4 , 就判别为P类)

样本	预测属于P的概率	真实类别
1	0.1	N
2	0.35	P
3	0.4	N
4	0.8	P



真实值	预测值	
	阳性	阴性
阳性	TP=1	FN=1
阴性	FP=1	TN=1

$$TPR = \frac{TP}{TP + FN} = 0.5$$
$$FPR = \frac{FP}{FP + TN} = 0.5$$



统计决策方法-ROC曲线

- 截断点为0.8(概率 ≥ 0.8 , 就判别为P类)

样本	预测属于P的概率	真实类别
1	0.1	N
2	0.35	P
3	0.4	N
4	0.8	P



真实值	预测值	
	阳性	阴性
阳性	TP=1	FN=1
阴性	FP=0	TN=2

$$TPR = \frac{TP}{TP + FN} = 0.5$$
$$FPR = \frac{FP}{FP + TN} = 0$$



统计决策方法-ROC曲线

- 截断点为0.9(概率 ≥ 0.9 , 就判别为P类)

样本	预测属于P的概率	真实类别
1	0.1	N
2	0.35	P
3	0.4	N
4	0.8	P




真实值	预测值	
	阳性	阴性
阳性	TP=0	FN=2
阴性	FP=0	TN=2

$$TPR = \frac{TP}{TP + FN} = 0$$
$$FPR = \frac{FP}{FP + TN} = 0$$



统计决策方法-ROC曲线

TPR	0	0.5	0.5	1	1
FPR	0	0	0.5	0.5	1





统计决策方法-作业

1 已知两个一维模式类别的类概率密度函数为

$$p(x | \omega_1) = \begin{cases} x, & 0 \leq x < 1 \\ 2 - x, & 1 \leq x \leq 2 \\ 0, & \text{else} \end{cases}$$

$$p(x | \omega_2) = \begin{cases} x - 1, & 1 \leq x < 2 \\ 3 - x, & 2 \leq x \leq 3 \\ 0, & \text{else} \end{cases}$$

先验概率分别为 $p(\omega_1) = 0.4$, $p(\omega_2) = 0.6$ 。试求最大后验概率判决函数以及总的分类错误概率 $P(e)$ 。



统计决策方法-作业

2 在图像识别中，假定有灌木丛和坦克两种类型，它们的先验概率分别是 0.8 和 0.2，损失函数如下表所示，其中 ω_1 和 ω_2 分别表示灌木丛和坦克， α_1 和 α_2 表示判决为灌木丛和坦克， α_3 表示拒绝判决。

	ω_1	ω_2
α_1	0.5	6
α_2	2	1
α_3	1.5	1.5

现在做了三次实验，从类概率密度函数曲线上查得三个样本 X_1, X_2, X_3 的类概率密度值如下：

$$X_1 : p(X_1 | \omega_1) = 0.1, p(X_1 | \omega_2) = 0.7$$

$$X_2 : p(X_2 | \omega_1) = 0.3, p(X_2 | \omega_2) = 0.45$$

$$X_3 : p(X_3 | \omega_1) = 0.6, p(X_3 | \omega_2) = 0.5$$



统计决策方法-作业

- (1) 试用贝叶斯最小误判概率准则判决三个样本各属于哪一个类型。
- (2) 假定只考虑前两种判决，试用贝叶斯最小风险判决准则判决三个样本各属于哪一个类
- (3) 把拒绝判决考虑在内，重新考核三次实验的结果。



模式识别-贝叶斯分类器

若干素材取自网络，特此致谢！





模式识别-贝叶斯分类器

谢谢聆听！

